nl2g

Спросил по-русски — получил график из базы данных

Сервис отвечает на вопросы к корпоративной базе готовыми графиками. Без аналитика, без SQL, без ожидания. Вопрос — и через минуту картинка, которую можно переделать словами.

Защита проекта · октябрь 2026 · github.com/kocharyandr/nl2g

Между вопросом и графиком сегодня стоит очередь

Руководитель

«Сколько продали по городам в этом квартале?»

→

Заявка аналитику

письмо или задача в трекере, ожидание очереди

→

Аналитик пишет SQL

ищет нужные таблицы, уточняет вопрос

→

Строит график в BI

подбирает тип, подписи, цвета

→

Ответ

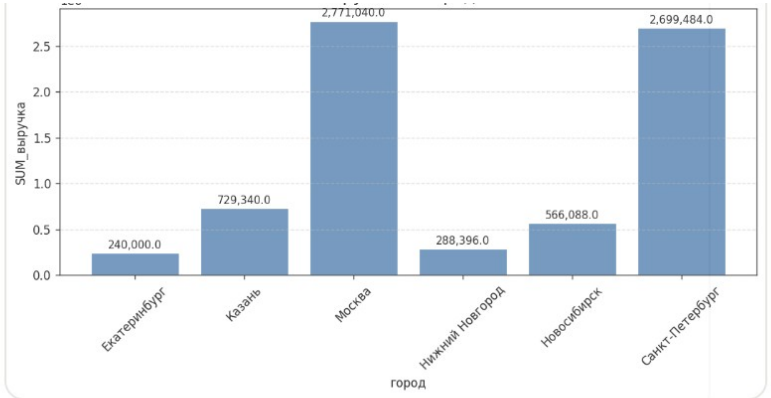
через часы или дни; на уточнение — заново

Что здесь дорого

Каждая стрелка — это человек и ожидание. Простой вопрос занимает время аналитика, а руководитель к моменту ответа уже задал следующий. Уточнение «а теперь по месяцам» запускает весь круг заново.

Вопрос в чат — через минуту график и запрос, которым он получен

построй график выручки по городам



Запрос возвращает суммарную выручку для каждого города.

строк: 6

▶ SQL-запрос

68 секунд

от вопроса до ответа: график, пояснение на русском, число строк и свёрнутый блок с запросом к базе.

Ниже на экране — кнопки «Подтвердить» и «Отмена».

Спрашивают как есть

«выручка по городам», «топ-5 товаров», «сколько магазинов в каждом городе» — без названий таблиц и полей.

Видно, откуда цифры

Под графиком лежит запрос к базе и число строк. Это проверяемый ответ, а не картинка на доверии.

Правят словами

«а теперь линией», «подпиши значения», «нарисуй в стиле акварели» — следующая версия приходит в тот же диалог.

Реальный экран сервиса, база «Розничная сеть»

Пять шагов от вопроса до картинки

1 Понять вопрос

Сервис определяет, о чём спросили, и находит в базе нужные таблицы и поля. Если вопрос неясен — переспрашивает.

2 Получить данные

Пишет запрос к базе, выполняет его и сам проверяет результат. Если запрос упал или вернул не то — переписывает, до трёх раз.

3 Построить график

Выбирает тип графика под данные и рисует его программным кодом — цифры на картинке в точности те, что в базе.

4 Показать человеку

Пользователь подтверждает график или правит словами: другой тип, цвет, подписи. Ничего не уходит дальше без его согласия.

5 Оформить

По желанию — правка картинки диффузионной моделью (фирменный стиль, иллюстрация для отчёта). LLM-судья проверяет, что данные на графике не пострадали.

Где здесь человек

Только на шаге 4. Всё до него — автоматически, всё после — по его команде. Это сознательное решение: сервис ускоряет аналитику, а не заменяет ответственность за цифры.

Внутри — семь сервисов, у каждого одна обязанность

Оркестратор (chart_agent)

Граф состояний на LangGraph: ведёт диалог, маршрутизирует намерение, останавливается на подтверждении человеком.

NL2SQL-агент (sql_agent)

Три роли с LoRA-адаптерами: schema-агент выбирает таблицы, SQL-агент пишет запрос, критик выполняет его и проверяет результат.

Исполнитель кода (code_executor)

Выполняет сгенерированный pandas- и matplotlib-код в отдельном процессе с таймаутом и возвращает картинку.

Диффузионная модель (diffusion_service)

FLUX.2 Klein 9B с дообученной LoRA: правит картинку графика по текстовому промпту.

LLM-судья (Qwen2.5-VL)

Сравнивает график до и после правки по 10 критериям: A1–A5 — правка выполнена, P1–P5 — данные сохранены.

Guardrails (GLiNER2)

Фильтр безопасности на входе и быстрая классификация намерения без обращения к большой модели.

Хранилище состояния (Redis)

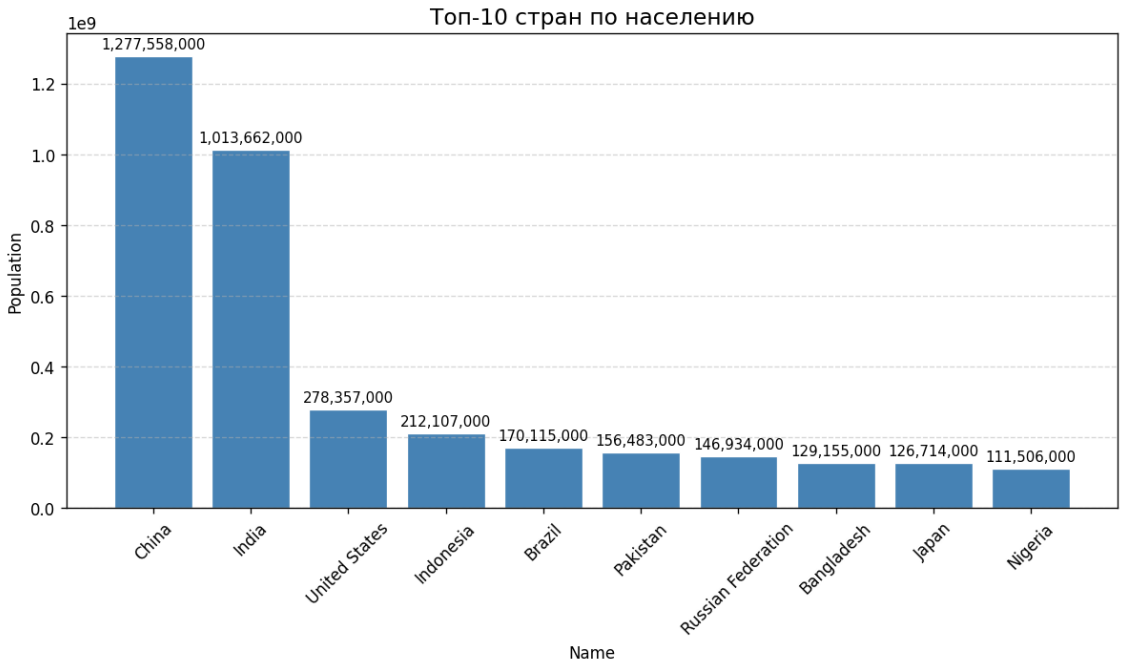
Состояние каждой сессии: правки применяются к нужному графику и переживают перезапуск сервиса.

Всё на своих серверах

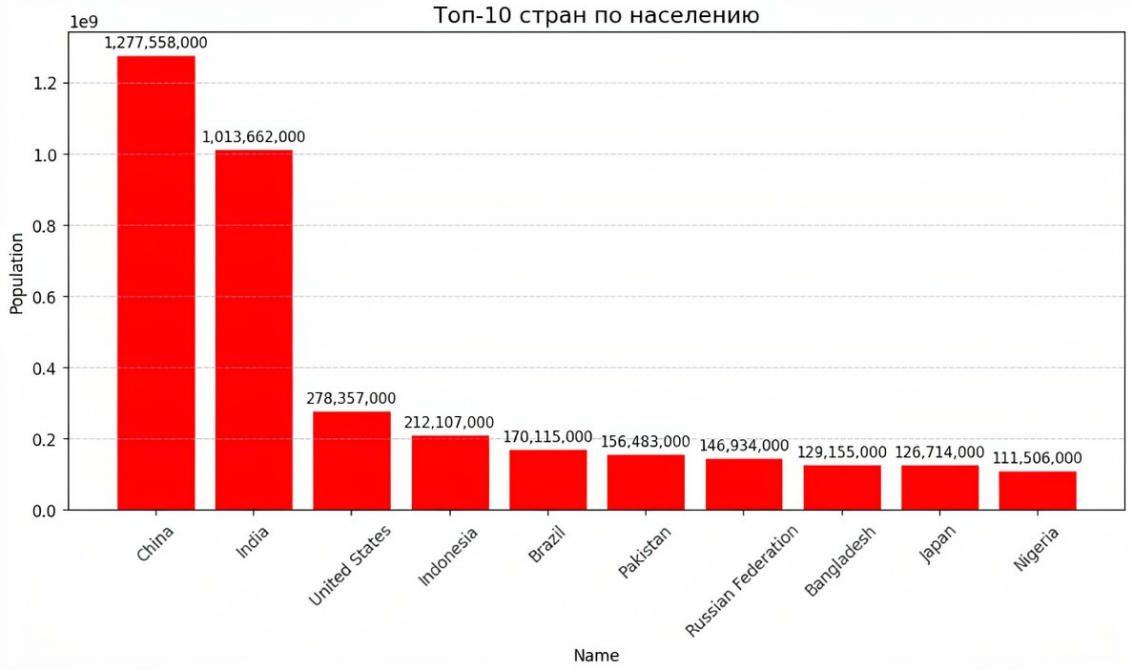
Модели работают локально: вопросы и данные из базы не покидают контур компании.

Оформление меняется одной фразой, цифры остаются на месте

До



После: «сделай столбцы ярко-красными, фон белый, оси чёрные»



Это правка картинки диффузионной моделью FLUX, а не перерисовка кодом: подписи, значения и пропорции столбцов сохранены. Такие правки нужны, когда график идёт в отчёт или презентацию в фирменных цветах.

Восемь графиков из десяти верны — поэтому под каждым есть запрос и кнопка подтверждения

Проверка на открытом русскоязычном наборе PAUQ: 100 вопросов к 19 базам, у каждого есть эталонный ответ. Считали честно: совпадение с эталоном, а не «похоже на правду».

97

из 100 вопросов превратились в график

80

графиков с цифрами, совпавшими с эталоном

68

правильных запросов к базе на русском (76 — на английском)

3

графика, где данные потерялись уже после верного запроса

Что это значит для пользователя

Два графика из десяти нужно перепроверить. Для этого под каждым показан запрос к базе и число строк, а график не уходит дальше без подтверждения.

Где ошибки

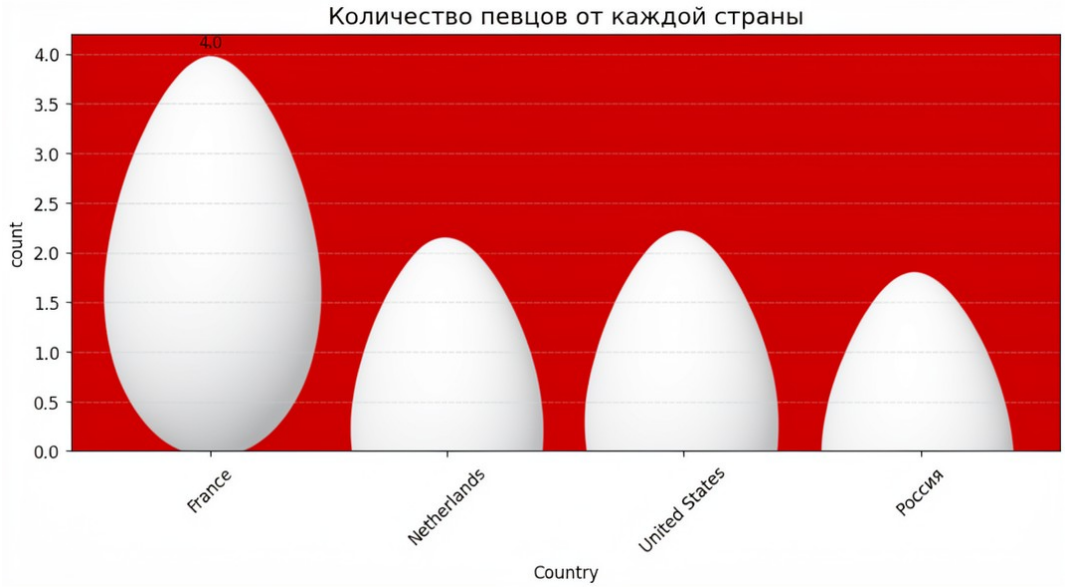
Вопросы, где нужно связать несколько таблиц, и группировки. Простые выборки и фильтры решаются одинаково хорошо на русском и английском.

Диффузионная правка справляется с цветом и формой, но реализм портит данные

82 правки на тех же графиках, три уровня сложности. Оценка — LLM-судья по 10 критериям; правка засчитана (AP), если выполнена и данные не искажены.

Что просили	Правок	Засчитано
Сменить цвета, фон, рамку	34	88%
Изменить форму элементов (скруглить, заменить на яйца)	32	72%
Перерисовать как реальные предметы	16	62%
Все правки	82	**77%**

Вывод для внедрения: цветовые и простые правки можно отдавать автомату, сложные — только с просмотром человеком. LLM-судья завышает оценку: согласие с экспертами к ≈ 0.6.



«Столбцы в форме яиц»: все четыре значения, кроме первого, равны 1, а яйца разной высоты. LLM-судья этого не заметил.

Сейчас всё работает на одном компьютере — для одного пользователя

≈ 1 мин

от вопроса до графика с SQL-запросом под ним

3–4,5 мин

правка картинки диффузионной моделью

1

пользователь за раз

Что занимает память	Сколько	Когда нужно
NL2SQL-агент, три LoRA-роли (Qwen2.5-Coder-14B)	27 ГБ	всегда
Оркестратор: модель qwen2.5-coder:14b	9 ГБ	всегда
Диффузионная модель FLUX.2 Klein 9B	33 ГБ	только для правок картинок
LLM-судья Qwen2.5-VL-7B	6 ГБ	только для оценки правок

Всего 75 ГБ при 51,5 ГБ на рабочей машине, поэтому сервисы включаются по очереди. Для демонстрации без диффузии хватает 36 ГБ.

Сервис читает базу, но не может её изменить

Только чтение

К базе допускается единственный тип запроса — выборка. Изменение, удаление и создание таблиц блокируются до выполнения.

Ограничение объёма

Запрос возвращает не больше заданного числа строк и прерывается по времени. Тяжёлый вопрос не положит базу.

Код в изоляции

Программа, рисующая график, выполняется в отдельном процессе с таймаутом. Ошибка в ней не затрагивает сервис.

Данные не уходят

Все модели работают на своём сервере. Ни вопросы, ни содержимое базы не передаются внешним сервисам.

Фильтр на входе

Запросы с недопустимым содержанием отсекаются до обработки.

След каждого ответа

К каждому графику приложен запрос, число строк и история правок — ответ можно проверить и воспроизвести.

Три ступени роста: рабочее место, отдел, компания

Сейчас

Одно рабочее место

Mac или ПК с 48–64 ГБ памяти

- 1 пользователь
- сервисы по очереди
- график за минуту, правка за 3–4,5 мин
- подходит для демонстрации и пилота на одном человеке

Шаг 1

Сервер для отдела

одна видеокарта 80 ГБ под LLM (vLLM) + одна 24–48 ГБ под FLUX

- все сервисы работают одновременно
- запросы нескольких людей обрабатываются пачкой
- график по-прежнему ≈ 1 мин, правка — секунды, а не минуты [замер на сервере]
- число одновременных пользователей — [замер]

Шаг 2

Кластер для компании

несколько серверов за балансировщиком

- оркестратор и code_executor — в нескольких копиях
- диффузия — через очередь, видеокарты добавляются по её длине
- состояние диалогов — в общем хранилище
- LLM-судья — в фоне, не задерживая ответ

Каждый сервис — отдельный контейнер; диффузия уже работала на сервере с видеокартой. Цифры в скобках появятся после первого запуска на сервере.

Что сервис делает плохо и что с этим делать

Слабое место	Насколько серьёзно	Что делаем
Сложные вопросы с несколькими таблицами	точность падает до 40–50%	дообучение на таких примерах; подсказка пользователю разбить вопрос
Русский хуже английского на 8 пунктов	слова вроде «старшеклассник» превращаются в лишние условия	русские примеры в обучающем наборе
Диффузионная модель искажает пропорции при сложных правках	каждая третья реалистичная правка	сложные правки — только с просмотром человеком
LLM-судья завышает оценку	пропускает часть искажений	выборочная ручная проверка, порог строже
Новый вопрос к базе во время ожидания подтверждения считается правкой	путает пользователя	учитывать состояние диалога при разборе сообщения
Поддерживается одна СУБД (SQLite)	корпоративные базы обычно на других	подключение PostgreSQL и аналогов — следующая версия

Что нужно, чтобы запустить пилот в отделе

1 Сервер

Одна видеокарта на 80 ГБ и одна на 24–48 ГБ, либо облачный аналог на время пилота. На нём снимаем цифры скорости и числа пользователей.

2 База и вопросы

Копия реальной базы только для чтения и 30–50 типовых вопросов отдела с известными правильными ответами — это станет мерилом точности на ваших данных.

3 Люди

Два-три сотрудника, которые две недели задают вопросы сервису вместо аналитика, и один аналитик, который проверяет ответы.

4 Критерий успеха

Доля графиков, принятых без исправлений, и время от вопроса до ответа по сравнению с текущим процессом. Пороги договариваемся до старта.

Установка — по инструкции из репозитория, скриптом; LoRA-адаптеры NL2SQL-агента лежат там же.

Что получает пользователь

Ответ за минуту

вместо очереди к аналитику — для типовых вопросов о продажах, остатках, динамике

Проверяемость

под каждым графиком запрос к базе; ничего не принимается без подтверждения

Оформление словами

от смены цвета до иллюстрации в фирменном стиле — в том же диалоге

Свои данные у себя

сервис работает в контуре компании, базу только читает

Код, инструкция по запуску, отчёты по замерам и эта презентация — github.com/kocharyandr/nl2g