nl2g

Вопрос на русском к базе данных → SQL → график → правка изображения

Пайплайн, примеры работы, оценка качества на PAUQ и оценка ресурсов

Октябрь 2026 · код и отчёты: github.com/kocharyandr/nl2g

Архитектура: семь сервисов



Путь одного запроса: шесть узлов графа и где в нём человек

1 interaction

определяет намерение: текст, CSV, база, изображение; при неясности переспрашивает

2 sql_source

вопрос → NL2SQL-агент → таблица; если в результате нет числовой меры — повторный запрос с подсказкой

3 table_node

LLM пишет pandas-план: оси, серии, агрегация; код выполняется, результат валидируется

4 plot_node

код matplotlib → code_executor; до 3 попыток рендера

5 approval

человек: подтвердить, отменить или правка текстом (повторная генерация кода)

6 image_diffusion + validation

после подтверждения: промпт → FLUX; LLM-судья оценивает до 3 итераций, выбирается лучшая

Медианы на 100 вопросах PAUQ: SQL 14 с · график готов через 52–66 с · правка диффузией 3–4,5 мин · оценка судьёй ≈ 1 мин

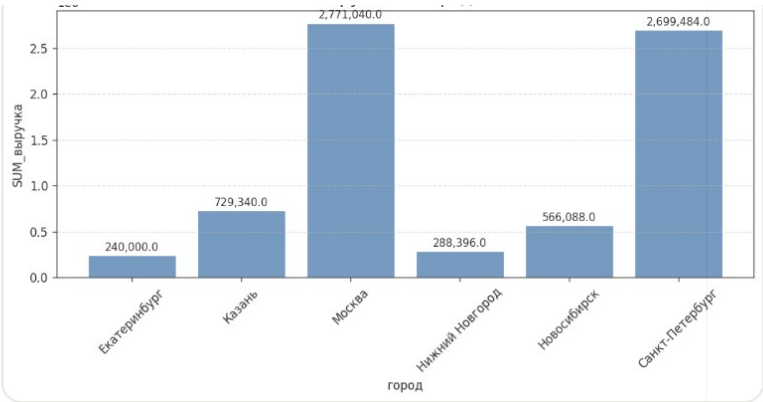
Модели и их роли

Сервис	Задача	Модель	Память
sql_agent · schema	выбор таблиц по Schema Profile и RAG-сужению	Qwen2.5-Coder-14B + LoRA (ранг 8, слои 32–47), GGUF q4	9 ГБ
sql_agent · sql	генерация SELECT по суженной схеме	то же, свой адаптер	9 ГБ
sql_agent · critic	выполнение запроса, разбор ошибки и результата, до 3 попыток	то же, свой адаптер	9 ГБ
chart_agent	намерение, pandas-план, код графика, промпт для диффузии	qwen2.5-coder:14b	9 ГБ
diffusion_service	правка изображения графика	FLUX.2 Klein 9B + LoRA rank 16 (2000 шагов), bf16, MPS	≈ 33 ГБ
LLM-судья	критерии A1–A5 (правка выполнена) и P1–P5 (данные сохранены)	qwen2.5vl:7b, temperature 0	6 ГБ
guardrails_api	фильтр безопасности, классификация намерения	GLiNER2 (fastino/gliner2-multi-v1)	< 1 ГБ

Адаптеры NL2SQL обучены на Spider; три роли — три копии базовой модели в Ollama (по 9 ГБ), так как Ollama не делит базу между адаптерами.

Пример: «построй график выручки по городам» — база РозничнаяСеть

построй график выручки по городам



Запрос возвращает суммарную выручку для каждого города.

строк: 6

▶ SQL-запрос

Что произошло за 68 секунд

- schema-агент выбрал таблицы магазины и продажи
- SQL-агент: SELECT м.город, SUM(п.выручка) FROM продажи п JOIN магазины м ON … GROUP BY м.город
- критик выполнил запрос: 6 строк, с первой попытки
- pandas-план: x = город, y = выручка; тип — столбцы; рендер с первой попытки

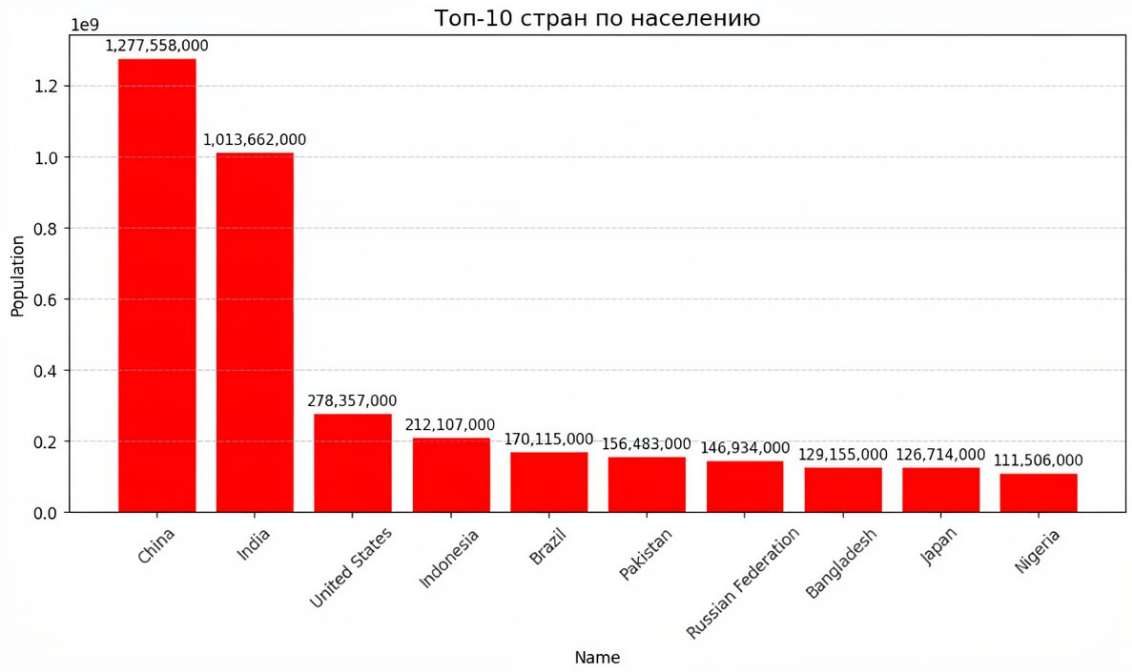
Ответ в чате

график, пояснение на русском («Запрос возвращает суммарную выручку для каждого города»), число строк и свёрнутый блок с SQL. Кнопки «Подтвердить» / «Отмена».

Правка до подтверждения: «а теперь линией» — 34–40 с, перегенерация кода графика.

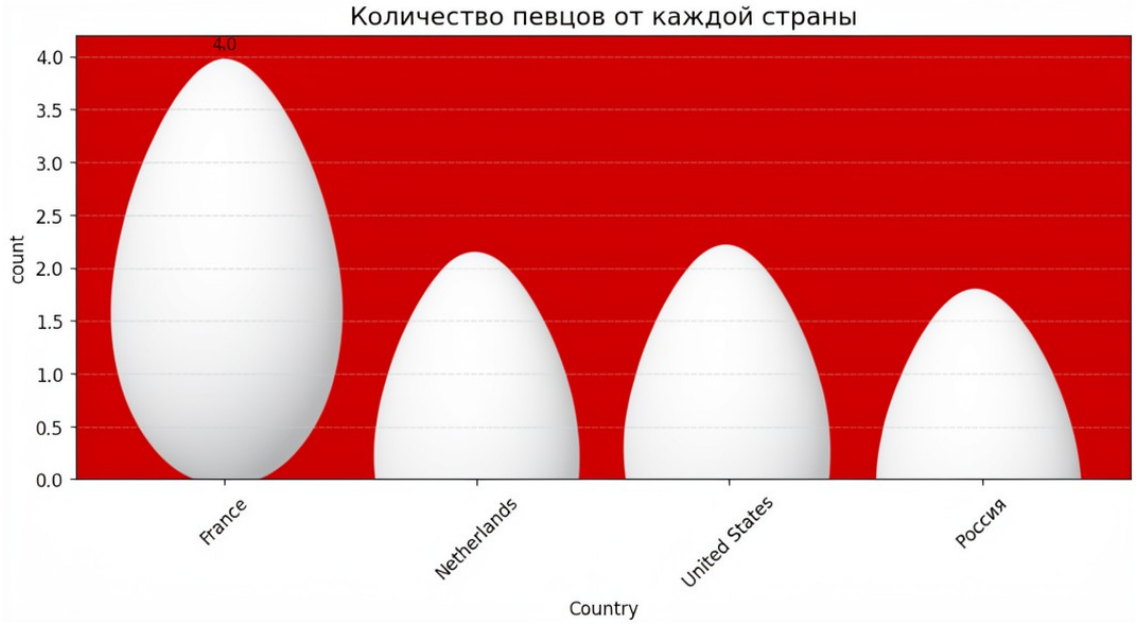
Пример: правка изображения после подтверждения, два уровня сложности

Уровень 1 — цвет: «замени цвета графика на ярко-красный, фон белый, сетка и оси чёрные»



Подписи, значения и пропорции сохранены. Судья: A=1, P=1.

Уровень 2 — форма: «сделай столбцы в форме белых яиц на красном фоне, высота яйца равна высоте столбца»



Значения 4, 1, 1, 1 — а яйца разной высоты: пропорции искажены. Судья поставил P=1, то есть искажения не заметил.

К каждому промпту добавляется «Сохрани график 1 в 1. Оси, подписи и масштаб должны быть идентичными исходному графику»; одна итерация FLUX, seed 42.

NL2SQL на PAUQ: 100 пар вопросов ru/en, EX 68% против 76%

PAUQ — русская адаптация Spider; взяты пары с одинаковым эталонным SQL. EX — совпадение множества строк результата с эталоном (порядок строк и колонок не учитывается).

68%

EX по-русски, ДИ 58–76%

76%

EX по-английски, ДИ 67–83%

Разрыв 8 п.п., Макнемар p = 0.021

оба верно 67 · только en 9 · только ru 1 · одинаковый SQL на двух языках 73 из 100. На 50 парах разрыв не был значим (p = 0.25). Медиана ответа 14 с, попыток критика 1.1.

Конструкция gold-SQL	n	EX ru	EX en
JOIN	35	40%	60%
GROUP BY	37	49%	65%
ORDER BY	26	69%	77%
WHERE	30	63%	63%
вложенный SELECT	17	59%	59%

Где теряется русский

Соединения таблиц и группировки. Типовой сбой — лексика: «старшеклассник» превращается в лишний фильтр grade = 12 (3 из 9 ошибок только на русском). Простые выборки и WHERE — одинаково на двух языках.

Полный пайплайн на 100 вопросах PAUQ: 97 графиков, Chart-EX 80

Из 9 874 русских вопросов PAUQ отобраны 959 пригодных для графика, из них 780 с агрегатом, топ-N или динамикой; взяты 91 из test и 9 из train. Chart-EX — числа каждой серии и подписи на графике совпадают с эталонным ответом.

97

график построен; 0 повторных рендеров

79

SQL-EX: результат SQL совпал с эталоном

80

Chart-EX: данные на графике совпали

3

потери на стыке: SQL верный, график нет

Верный SQL → ?	график верен	график неверен
SQL верный	76	3
SQL неверный	4	14

Три потери на стыке

Дата, хранящаяся числом 19870119, прочитана pandas как наносекунды от 1970 — 1 504 нечитаемых подписей (два вопроса). В двухсерийном графике планировщик поставил минимальный вес на ось X, а пол сделал сериями.

Без графика: ошибка 500 в plot_node, ответ одним числом, неоднозначная колонка в SQL.

Правки диффузией на тех же графиках: AP 77%, от 88% до 62% с ростом сложности

Промпты трёх уровней сложности (цвет → форма элементов → реализм), 59 из 100 — с «яйцом»; оценены 82 правки, 15 не выполнены из-за нехватки памяти (HTTP 503). Судья — Qwen2.5-VL-7b, temperature 0; A, P, AP = 1, если пройдены все критерии группы.

Срез	правок	A	P	AP
уровень 1 · цвет	34	88%	100%	**88%**
уровень 2 · форма	32	75%	91%	**72%**
уровень 3 · реализм	16	81%	75%	**62%**
с яйцом	48	77%	85%	**69%**
без яйца	34	88%	100%	**88%**
всего	82	82%	91%	**77%**

Та же зависимость, что на английских данных

Чем сложнее промпт, тем ниже AP; реализм чаще всего нарушает P (75%).

Судья смещён в плюс

Яйца разной высоты при равных значениях получили P3 «пропорции сохранены». Согласие судьи с экспертами к ≈ 0.6, поэтому AP — верхняя оценка; нужна выборочная ручная разметка.

Ресурсы на одной машине: 75 ГБ моделей при 51,5 ГБ памяти — работа в три фазы



▲ 51,5 ГБ общей памяти Mac; FLUX и три LoRA-роли вместе уходят в swap — отсюда ошибки 503 и 4,5 мин на правку

Фаза 1 · данные и график

36 ГБ

три LoRA-роли + оркестратор, модели в памяти (KEEP_ALIVE 30 мин); ответ ≈ 1 мин; рабочий режим без правок изображений

Фаза 2 · правка диффузией

42 ГБ

LoRA-роли выгружены, остаются оркестратор + FLUX; 3–4,5 мин на изображение; при автовалидации ×3

Фаза 3 · LLM-судья

6 ГБ

диффузия остановлена; ≈ 1 мин на пару изображений

Диск	Время	Пользователи
GGUF-модели 42 ГБ + веса FLUX ≈ 35 ГБ ≈ 80 ГБ; базы PAUQ, Spider, BIRD, KaggleDBQA — ещё несколько ГБ	100 вопросов полного цикла ≈ 9 ч; 97% времени — диффузия	один; сервисы переключаются скриптом start_all.sh

Масштабирование: три конфигурации

Сейчас

Рабочая станция

Mac или ПК, 48–64 ГБ общей памяти

- 1 пользователь, сервисы по фазам
- LoRA-роли — три копии базы по 9 ГБ
- график ≈ 1 мин, правка 3–4,5 мин
- 100 вопросов с правками ≈ 9 ч

Шаг 1

Сервер с двумя GPU

GPU A 80 ГБ: vLLM, одна база Qwen 14B + 3 LoRA-адаптера + VL-судья · GPU B 24–48 ГБ: FLUX (bf16 ≈ 18 ГБ трансформер)

- все фазы одновременно, батчинг запросов
- правка — секунды вместо минут [замер]
- одновременных пользователей — [замер]
- код готов: контейнеры у каждого сервиса, Ollama → vLLM без правок (OpenAI-протокол)

Шаг 2

Кластер

несколько серверов за балансировщиком

- оркестратор, executor, guardrails — реплики, состояние в Redis
- диффузия — очередь задач, GPU добавляются по её длине
- пул LLM отдельно от пула диффузии
- судья — асинхронно после ответа

Узкое место — диффузия (97% времени цикла): масштабируется числом GPU и очередью. Память для шага 1 посчитана из размеров весов; цифры в скобках — после первого запуска на сервере.

Что пришлось исправить на стыке сервисов

Симптом	Причина	Исправление
График из одной точки: SQL-агент отвечает count(*) или AVG	в Spider/PAUQ числа объявлены как TEXT (MPG, Horsepower, строки «null»); узел не видел меры и просил добавить агрегат	sql_source: мера определяется по значениям, «null» — пропуск
Круговая диаграмма без подписей секторов	планировщик читал «без оси X» буквально и выбрасывал колонку категорий	table_node: круговая без категорий → повторный план; подпись из индекса
Ответ в чате зависает без ошибок	code_executor: результат больше 64 КБ блокировал канал процесса	чтение очереди до join; 5 тестов
LLM-судья ставит всем 1.0	валидатор работал на текстовой модели — изображений не видел	qwen2.5vl:7b; парсер вердикта понимает строки и синонимы ключа
Цветовые правки не доходят до диффузии	роутер правок по дизайну уводит «цвет, тип» в код matplotlib	сигнальные слова в промпте («нарисуй нейросетью»)
Вопрос к базе во время ожидания подтверждения считается правкой	интерфейс шлёт любой текст как decision=edit	описано как ограничение; план — учитывать стадию при маршрутизации

Тесты: 61 в chart_agent (44 на источник SQL), 72 в sql_agent.

Ограничения и дальнейшая работа

Ограничения

- Судья завышает P; AP — верхняя оценка, нужна ручная разметка части русских правок
- 82 из 97 правок оценены: 15 упали из-за памяти, не из-за модели
- В PAUQ почти нет динамики и рассеяний: 31 линия и 2 scatter из 780 вопросов
- Поддерживается только SQLite
- Все замеры — на одной машине без GPU

Дальнейшая работа

- Приведение типов на стыке SQL → pandas (дата-число): 2 из 3 потерь Chart-EX
- Маршрутизация вопроса к базе по намерению и стадии диалога, а не только по переключателю
- Запуск на сервере с GPU: vLLM multi-LoRA + отдельная GPU под FLUX; замер скорости и числа пользователей
- PAUQ на 300 парах; повтор правок на 3–5 seed
- Подключение PostgreSQL